

Introdução:

O presente trabalho tem como objetivo realizar um estudo aprofundado da **execução orçamentária do Governo Federal brasileiro** no período de 2015 a 2024. A análise da aplicação de recursos públicos é essencial para compreender como o orçamento federal é alocado entre diferentes setores e programas, permitindo avaliar eficiência, gastos, prioridades de investimento e transparência na gestão dos recursos públicos.

O trabalho utiliza exclusivamente dados oficiais disponibilizados ao público pelo **Portal da Transparência**, mantido pela Controladoria-Geral da União (CGU). A partir desses dados, busca-se identificar:

- Padrões de gasto de cada Presidente ao longo do mandato em diferentes áreas da administração pública, como Saúde, Educação, Segurança Pública e Tecnologia da Informação;
- Comparações entre diferentes mandatos presidenciais quanto à alocação e execução do orçamento;
- Tendências e alterações de comportamento dos gastos em períodos específicos, incluindo anos eleitorais e o contexto da pandemia da COVID-19.

Dessa forma, este estudo proporciona uma **visão estruturada e detalhada da execução orçamentária federal**, permitindo compreender não apenas os valores gastos, mas também as decisões e prioridades do governo ao longo dos últimos nove anos.

Extração de Dados:

Para reproduzir ou atualizar os dados do projeto, siga os passos detalhados abaixo:

1. **Acesse o Portal da Transparência**
Abra diretamente a página de downloads de dados do governo federal: [Portal da Transparência – Downloads](#)
2. **Baixe os arquivos utilizados no projeto**
Este estudo faz uso dos seguintes conjuntos oficiais de dados:
 - **Despesas Públicas** → **Execução da Despesa**
 - **Cartão de Pagamento** → **Cartão de Pagamento do Governo Federal (CPGF)**
 - **Viagens a Serviço** → **Viagens a Serviço**
3. **Selecione o período desejado** - Para cada conjunto de dados, escolha o **ano (exercício)** e o **mês** que deseja analisar.
4. **Realize o download** - Clique no botão **“Baixar”** para obter o arquivo, geralmente no formato CSV. Salve os arquivos na pasta de dados do projeto, garantindo que estejam organizados para posterior processamento e análise.

Para compreender detalhadamente os dados extraídos, bem como a estrutura do banco de dados, incluindo a organização das tabelas e seus relacionamentos, consulte o 'Dicionário de Dados' e a seção de 'Modelagem Lógica e Física', disponíveis na pasta 'Documentação'.

Arquitetura de Dados:

Engenharia de Dados:

O objetivo da Engenharia de dados nesse processo é automatizar a **extração, transformação e carga (ETL)** de dados públicos a partir de arquivos CSV para o banco de dados **ProjetoGastosGovernamentais**, estruturando-os em tabelas relacionais normalizadas para análise posterior.

O processo inicia com a ingestão de três arquivos .zip de fontes distintas: despesas públicas, gastos com cartões corporativos e gastos com viagens.

A etapa de Extração é o ponto de partida, onde os arquivos comprimidos são descompactados e seus conteúdos são processados:

1. O arquivo despesas.zip contém dados de despesas governamentais e, após a extração, gera o arquivo despesas.csv.
2. O arquivo cartao_corporativo.zip armazena informações sobre o uso de cartões corporativos, resultando no arquivo cartao.csv.
3. O arquivo viagens.zip é a fonte mais complexa, descompactando-se em múltiplos arquivos CSV: viagem.csv, trecho.csv, pagamento.csv e passagem.csv.

Após a extração, o projeto prossegue com a etapa de Transformação. Nesta fase, o arquivo trecho.csv é descartado, pois, após uma análise inicial, sua utilidade foi considerada irrelevante para os objetivos finais do projeto. Os demais arquivos (despesas.csv, cartao.csv, viagem.csv, pagamento.csv, passagem.csv) passam por processos de limpeza e padronização, preparando-os para o carregamento final em um banco de dados relacional.

Para documentar o projeto de ETL, vamos descrever as stored procedures e o fluxo de processamento. A documentação a seguir detalha cada etapa do processo ETL, desde a extração dos dados de um arquivo CSV até o carregamento final em um banco de dados relacional.

DESPESAS:

Stored Procedures

O processo é orquestrado por uma procedure principal (SP_ETL_DESPESAS) que executa as demais em uma sequência lógica.

1. SP_ETL_DESPESAS

Essa é a procedure de controle principal. Ela recebe o caminho do arquivo CSV como parâmetro e coordena a execução das outras procedures na ordem correta, garantindo que todas as etapas do ETL sejam concluídas.

- **Parâmetro:**
 - @CAMINHO_CSV: O caminho completo do arquivo CSV a ser processado.
- **Fluxo de Execução:**
 1. Chama SP_EXTRAI_CSV_DESPESAS para a etapa de **Extração**.
 2. Chama SP_TRATA_CSV_DESPESAS para a etapa de **Transformação**.
 3. Chama SP_CARREGA_CSV_DESPESAS para a etapa de **Carregamento**.
 4. Limpa e remove as tabelas temporárias (##temp_despesas_Convertido e ##temp_depesas) criadas durante o processo para liberar recursos.

2. SP_EXTRAI_CSV_DESPESAS

Responsável pela fase de **Extração**. Ela importa os dados brutos diretamente do arquivo CSV para uma tabela temporária no banco de dados.

- **Parâmetro:**
 - @CAMINHO: O caminho do arquivo CSV.
- **Lógica Principal:**
 - Cria uma tabela temporária global chamada ##temp_depesas, onde todas as colunas são do tipo VARCHAR(MAX) para acomodar os dados brutos sem erros de tipo.
 - Utiliza o comando BULK INSERT para ler o arquivo CSV.
 - Configura os parâmetros de leitura: o delimitador de campo é o ponto e vírgula (;), o terminador de linha é o \n e a primeira linha é ignorada (cabeçalho).

3. SP_TRATA_CSV_DESPESAS

Responsável pela fase de **Transformação**. Nesta etapa, os dados são limpos e preparados para o carregamento final.

- **Lógica Principal:**
 - **Limpeza de caracteres:** Remove as aspas duplas (") de todas as colunas na tabela temporária ##temp_depesas.
 - **Filtragem de dados:** Exclui as linhas onde a colunaCodigoOrgaoSuperior é igual a -1.
 - **Remoção de colunas:** Remove colunas que não serão utilizadas no modelo final para otimizar o processo.
 - **Criação de nova tabela temporária:** Cria uma segunda tabela temporária (##temp_despesas_Convertido) com os tipos de dados corretos (ex: INT, DATE, DECIMAL).
 - **Conversão de tipos:** Insere os dados da tabela bruta (##temp_depesas) na nova tabela (##temp_despesas_Convertido), realizando as conversões de tipo necessárias. O script lida com valores vazios (") e -1 convertendo-os para NULL ou 0 conforme a necessidade.

- **Substituição de caracteres:** Substitui vírgulas (,) por pontos (.) em colunas de valores numéricos para permitir a conversão para DECIMAL.

4. SP_CARREGA_CSV_DESPESAS

Responsável pela fase de **Carregamento**. Esta procedure carrega os dados limpos e transformados nas tabelas de fato e dimensão do banco de dados.

- **Lógica Principal:**
 - **Carregamento das Dimensões:** Utiliza **CTEs (Common Table Expressions)** e a função ROW_NUMBER() para identificar registros únicos em cada dimensão (ex: OrgaoSuperior, Gestao, UnidadeGestora).
 - Insere os dados nas tabelas de dimensão, evitando a duplicação de registros com a cláusula NOT EXISTS.
 - **Carregamento da Tabela Fato:** Insere os dados processados na tabela de fatos Despesas.
 - Associa os registros da tabela Despesas com a dimensão Mandato (que representa a gestão presidencial) através de uma junção por data (AnoMesLancamento). Isso permite que as despesas sejam analisadas no contexto de cada governo.

5. SP_CARREGA_PRESIDENTE

Esta procedure é de **setup inicial**. Ela não faz parte do fluxo de ETL regular, mas é crucial para preencher as tabelas Presidente e Mandato com dados históricos antes que o ETL seja executado pela primeira vez.

- **Lógica Principal:**
 - Insere registros para os presidentes e seus respectivos mandatos no Brasil, incluindo as datas de início e fim de cada gestão.
 - A tabela Mandato é essencial para a junção na procedure SP_CARREGA_CSV_DESPESAS, fornecendo o contexto de qual presidente estava no poder em cada data de lançamento de despesa.

Viagem:

O processo é composto por um conjunto de *stored procedures* em T-SQL, que extraem dados de três arquivos CSV diferentes (viagem.csv, passagem.csv e pagamento.csv), transformam-nos e os carregam em tabelas de um banco de dados relacional.

O objetivo é integrar dados de múltiplas fontes para fornecer uma visão completa das despesas de viagem, incluindo detalhes da viagem, passagens e pagamentos.

Stored Procedures

As procedures estão organizadas em grupos, cada um responsável por um dos arquivos de origem, além de uma procedure para cada etapa do processo (extração, tratamento e carga).

1. ETL de Dados de Viagem (viagem.csv)

Este grupo de procedimentos é responsável por processar o arquivo principal que detalha as viagens.

- **SP_ETL_VIAGEM:** A procedure mestra para o arquivo viagem.csv. Ela orquestra a execução das demais procedures para este fluxo.
 - **Parâmetro:** @CAMINHO_CSV (caminho do arquivo viagem.csv).
 - **Fluxo:** Executa SP_EXTRAI_VIAGEM, SP_TRATA_VIAGEM e SP_CARREGA_VIAGEM, e depois descarta as tabelas temporárias.
- **SP_EXTRAI_VIAGEM:** Extrai os dados do viagem.csv.
 - Cria uma tabela temporária (##temp_viagem_csv_tb) com colunas do tipo VARCHAR(MAX) para importar os dados brutos via BULK INSERT.
 - Define o delimitador de campo como ; e o terminador de linha como \n, pulando a primeira linha (cabeçalho).
- **SP_TRATA_VIAGEM:** Transforma os dados brutos.
 - **Limpeza:** Remove aspas duplas (") de todas as colunas.
 - **Filtragem:** Exclui linhas com valores inválidos ou nulos nas colunas de valor e no identificador do processo de viagem.
 - **Remoção de Colunas:** Descarta colunas que não são relevantes para o modelo final.
 - **Conversão de Tipos:** Cria uma nova tabela temporária (##temp_viajens_convertido_tb) com os tipos de dados corretos (INT, DATE, DECIMAL). Converte os dados brutos, substituindo vírgulas por pontos para valores decimais e tratando valores inválidos.
- **SP_CARREGA_VIAGEM:** Carrega os dados nas tabelas finais.
 - Usa **CTEs (Common Table Expressions)** para identificar registros únicos e carregar as tabelas de dimensão OrgaoSuperior e OrgaoSolicitante, prevenindo duplicidade.
 - Carrega a tabela de fatos Viagem com as informações processadas, calculando o total de gastos (ValorDiarias + ValorPassagens + ValorOutrosGastos).

2. ETL de Dados de Passagem (passagem.csv)

Este grupo de procedimentos é responsável por processar os dados detalhados de passagens.

- **SP_ETL_PASSAGEM:** Procedure mestra para o arquivo passagem.csv.
 - **Parâmetro:** @CAMINHO_CSV (caminho do arquivo passagem.csv).
 - **Fluxo:** Executa SP_EXTRAI_PASSAGEM, SP_TRATA_PASSAGEM e SP_CARREGA_PASSAGEM, e depois descarta as tabelas temporárias.
- **SP_EXTRAI_PASSAGEM:** Extrai os dados do passagem.csv.
 - Cria uma tabela temporária (##tb_passagem_csv_tb) para a importação via BULK INSERT.

- **SP_TRATA_PASSAGEM:** Transforma os dados brutos.
 - **Limpeza:** Remove aspas duplas (") e descarta colunas irrelevantes.
 - **Conversão de Tipos:** Cria uma nova tabela temporária (##temp_passagem_convertido_tb) com os tipos de dados adequados.
 - **Concatenação:** Combina as colunas de origem e destino (País e UF) em uma única coluna para simplificar o modelo.
- **SP_CARREGA_PASSAGEM:** Carrega os dados na tabela final Passagem.
 - Insere os registros na tabela Passagem, juntando com a tabela Viagem pelo IdentificadorDoprocessoDeViagem.

3. ETL de Dados de Pagamento (pagamento.csv)

Este grupo de procedimentos é responsável por processar os dados financeiros de cada viagem.

- **SP_ETL_PAGAMENTO:** Procedure mestra para o arquivo pagamento.csv.
 - **Parâmetro:** @CAMINHO_CSV (caminho do arquivo pagamento.csv).
 - **Fluxo:** Executa SP_EXTRAI_PAGAMENTO, SP_TRATA_PAGAMENTO e SP_CARREGA_PAGAMENTO, e depois descarta as tabelas temporárias.
- **SP_EXTRAI_PAGAMENTO:** Extrai os dados do pagamento.csv.
 - Cria uma tabela temporária (##temp_pagamneto_csv_tb) para a importação via BULK INSERT.
- **SP_TRATA_PAGAMENTO:** Transforma os dados brutos.
 - **Limpeza:** Remove aspas duplas (") e descarta a coluna NumeroDaPropostaPCDP.
 - **Conversão de Tipos:** Cria uma nova tabela temporária (##temp_pagamento_convertido_tb) e converte os tipos de dados, lidando com valores inválidos.
- **SP_CARREGA_PAGAMENTO:** Carrega os dados nas tabelas finais.
 - Usa **CTEs** para carregar as tabelas de dimensão OrgaoSuperior, OrgaoPagador e UnidadeGestoraPagadora.
 - Carrega a tabela Pagamento, juntando com a tabela Viagem para associar cada pagamento a um processo de viagem específico.

Cartão:

O processo de ETL para os dados de Cartão de Pagamento é orquestrado por uma procedure principal (SP_ETL_CARTAO) que gerencia a execução das procedures especializadas em sequência, garantindo um fluxo de trabalho modular e organizado.

Stored Procedures

O sistema é composto por 4 procedures principais para o fluxo de ETL e uma procedure auxiliar de setup.

1. SP_ETL_CARTAO Essa é a procedure de controle principal (orquestradora ou "Gerente") para o ETL de Gastos com Cartão de Pagamento. Ela coordena a execução de todas as outras procedures na ordem correta.

- **Parâmetro:**
 - @CAMINHO_CSV: O caminho completo do arquivo CSV de Cartão de Pagamento (...CPGF.csv) a ser processado.
- **Fluxo de Execução:**
 - Chama SP_CARREGA_PRESENTE para garantir que os dados de suporte de mandatos existam.
 - Chama SP_EXTRAI_CSV_CARTAO para a etapa de Extração.
 - Chama SP_TRATA_CSV_CARTAO para a etapa de Transformação.
 - Chama SP_CARREGA_CSV_CARTAO para a etapa de Carregamento.
 - Realiza a limpeza final, removendo as tabelas temporárias globais (##temp_cartao_bruto e ##temp_cartao_convertido) criadas durante o processo.

2. SP_EXTRAI_CSV_CARTAO Responsável pela fase de Extração. Sua única função é importar os dados brutos diretamente do arquivo CSV para uma tabela temporária.

- **Parâmetro:**
 - @CAMINHO_DO_ARQUIVO: O caminho do arquivo CSV recebido da procedure principal.
- **Lógica Principal:**
 - Cria uma tabela temporária global chamada ##temp_cartao_bruto, onde todas as colunas são do tipo NVARCHAR(MAX) para acomodar os dados brutos sem erros de tipo.
 - Utiliza o comando BULK INSERT para ler o arquivo CSV e carregar seu conteúdo na tabela temporária.
 - Configura os parâmetros de leitura: ignora a primeira linha (cabeçalho), define o delimitador de campo como ponto e vírgula (;) e a CODEPAGE como 1252 para compatibilidade de caracteres do português.

3. SP_TRATA_CSV_CARTAO Responsável pela fase de Transformação. Nesta etapa, os dados brutos são limpos, as regras de negócio são aplicadas e os tipos de dados são convertidos.

- **Lógica Principal:**
 - **Limpeza de Caracteres:** Remove aspas duplas (") de todas as colunas na tabela ##temp_cartao_bruto.
 - **Criação de Tabela Convertida:** Cria uma segunda tabela temporária global (##temp_cartao_convertido) com os tipos de dados finais e corretos (ex: INT, DATE, DECIMAL).
 - **Conversão de Tipos:** Insere os dados da tabela bruta na nova tabela convertida, realizando as conversões de tipo.
 - **Tratamento de Datas Inválidas:** Implementa uma lógica "inteligente" para não perder transações. Se uma data no arquivo for inválida (em branco, 2015-02-29, etc.), a procedure cria uma **data provisória** baseada no ANO EXTRATO e MÊS EXTRATO do próprio arquivo (ex: para um arquivo de Fev/2015, a data provisória se torna 2015-02-01). Isso garante que a transação seja registrada e marcada para análise posterior.

4. SP_CARREGA_CSV_CARTAO Responsável pela fase de Carregamento. Esta procedure carrega os dados já limpos e transformados nas tabelas permanentes (fato e dimensão) do banco de dados.

- **Lógica Principal:**
 - **Carregamento das Dimensões:** Utiliza a cláusula NOT EXISTS para inserir apenas registros únicos nas tabelas de dimensão (OrgaoSuperior, OrgaoSubordinado, UnidadeGestora), evitando a duplicação de dados que já foram carregados de arquivos anteriores.
 - **Carregamento da Tabela Fato:** Insere os registros processados na tabela de fatos GastosCartao.
 - **Geração de IDs:** A chave primária (IdGastosCartao) é gerada de forma sequencial, continuando a partir do último ID existente na tabela. Isso permite a carga incremental de múltiplos arquivos sem conflitos.
 - **Associação de Mandato:** Associa cada registro de gasto ao IdMandato correto, fazendo uma junção (LEFT JOIN) com a tabela Mandato com base na DataTransacao daquele gasto.

5. SP_CARREGA_PRESIDENTE Esta é uma procedure de setup inicial. Ela não faz parte do fluxo de ETL regular, mas é crucial para preencher as tabelas Presidente e Mandato com dados históricos antes que o ETL seja executado pela primeira vez.

- **Lógica Principal:**
 - Verifica se a tabela Presidente está vazia.
 - Se estiver, insere os registros para os presidentes e seus respectivos mandatos no Brasil.

Análise de Dados: